

HW3 多元線性回歸分析報告

主程式：HW3.ipynb

資料集：Kaggle - Social Anxiety Dataset

資料檔：enhanced_anxiety_dataset.csv

一、研究主題與資料集來源

本作業使用 Kaggle 上的 Social Anxiety Dataset 作為分析資料，目標是利用個人的生活習慣、背景資料與生理數據，建立多元線性回歸模型來預測焦慮程度 Anxiety Level (1-10)。

資料來源：

- Kaggle Dataset: Social Anxiety Dataset
- Kaggle Link: <https://www.kaggle.com/datasets/natezhang123/social-anxiety-dataset> (<https://www.kaggle.com/datasets/natezhang123/social-anxiety-dataset>).
- 本地資料檔：enhanced_anxiety_dataset.csv

資料集共有 11,000 筆資料、19 個欄位，包含數值型與類別型變數，沒有缺失值。目標變數為 Anxiety Level (1-10)，可視為 1 到 10 分的連續型焦慮程度分數，因此適合使用多元線性回歸進行分析。

二、CRISP-DM 分析流程

1. Business Understanding

本分析想探討生活習慣、壓力狀態、個人背景與生理數據是否會影響焦慮程度。焦慮程度可能與睡眠、運動、咖啡因攝取、壓力程度、心率、治療次數、飲食品質等因素有關，因此本作業使用這些變數建立 Multiple Linear Regression 模型。

成功標準如下：

- 使用 `sklearn.linear_model.LinearRegression` 建立多元線性回歸模型。
- 使用 R2、MAE、RMSE 評估模型表現。
- 完成特徵選擇，並比較不同模型版本。
- 繪製預測圖與 95% confidence interval。
- 根據回歸係數說明變數對焦慮程度的正向或負向影響。

本模型僅作為課堂作業與資料科學分析練習，不可作為正式醫療診斷或心理健康判定工具。


2. Data Understanding

使用 `pandas` 讀取資料後，確認資料共有 11,000 筆、19 欄。資料沒有缺失值，也沒有重複資料。Notebook 中已檢查：


- `df.shape`
- `df.info()`
- `df.describe(include="all")`
- 缺失值檢查
- 重複資料檢查

主要圖表：


- 目標變數分佈圖： `outputs/anxiety_level_distribution.png`



● 重要特徵散佈圖： outputs/important_feature_scatterplots.png



● 數值特徵相關係數熱力圖： outputs/numeric_correlation_heatmap.png



初步觀察：

- Stress Level (1-10) 與焦慮程度呈現明顯正向關係。
- Caffeine Intake (mg/day) 也可能與較高焦慮程度相關。
- Sleep Hours 、 Physical Activity (hrs/week) 可能與較低焦慮程度相關。

3. Data Preparation

本階段先複製原始資料為 `model_df`，避免直接修改原始資料。接著進行特徵工程、類別編碼、資料切分與標準化。

新增衍生變數：

- `Sleep_Activity_Score = Sleep Hours * Physical Activity (hrs/week)`
- `Stimulant_Index = Caffeine Intake (mg/day) + Alcohol Consumption (drinks/week) * 10`
- `Diet_Stimulant_Balance = Diet Quality (1-10) - (Stimulant_Index / 100)`

類別變數處理：

- Yes/No 二元欄位轉換為 1/0，例如 `Smoking`、`Medication`、`Dizziness`。
- Gender 與 Occupation 使用 `pd.get_dummies(..., drop_first=True)` 進行 One-Hot Encoding。

資料切分與標準化：

- 訓練集：80%，共 8,800 筆。
- 測試集：20%，共 2,200 筆。
- `random_state=42`，確保結果可重現。
- 使用 `StandardScaler` 對模型輸入欄位進行標準化。

4. Modeling

依作業要求，三個模型皆使用 `sklearn.linear_model.LinearRegression`，沒有使用 Random Forest 或 Gradient Boosting 作為主模型。

Model 1 Baseline：

- 使用所有數值化與轉換後的變數建立多元線性回歸模型。

Model 2 Feature Selection :

- 依據 Model 1 標準化後的係數絕對值，挑選前 10 個重要變數重新訓練模型。
- 此模型符合特徵選擇要求。

Model 3 Interaction Terms :

- 加入交互作用項，檢查變數之間是否存在共同影響。
- 加入的交互作用項包含：
 - Stress_x_Sleep
 - Stress_x_Caffeine
 - Stress_x_PhysicalActivity
 - Sleep_x_DietQuality

5. Evaluation

本作業是回歸問題，因此不使用分類任務的 accuracy，而是使用 R2、MAE、RMSE 評估模型表現。

模型評估結果如下：



Model	R2	MAE	RMSE
Model 1 Baseline	0.734041	0.880994	1.110120
Model 2 Feature Selection	0.727553	0.893405	1.123579
Model 3 Interaction Terms	0.744755	0.870597	1.087530

最佳模型為 Model 3 Interaction Terms：

- R2 = 0.744755，代表模型約可解釋 74.48% 的焦慮分數變異。
- MAE = 0.870597，代表在 1 到 10 分焦慮量表中，平均預測誤差約 0.87 分。
- RMSE = 1.087530，代表加重較大誤差後，整體誤差約 1.09 分。

預測圖與信賴區間：

- 預測圖檔案： `outputs/prediction_plot_with_ci.png`




- 圖中使用 `seaborn.regplot(ci=95)`，因此 confidence interval 設定為 95%。
- 此 confidence interval 代表平均預測回歸線的不確定範圍，不是每一筆個人樣本的保證範圍。

- 另外輸出 `outputs/prediction_confidence_interval_summary.csv`，列出 Actual Anxiety Level 1 到 10 對應的平均預測值 95% confidence interval。

模型比較圖：

- `outputs/model_evaluation_comparison.png`



- R2 是越高越好，MAE 與 RMSE 是越低越好，因此圖中將 R2 與誤差指標分開呈現，避免誤讀。

6. Deployment

從最佳模型與回歸係數方向可以整理出以下結論：

- 壓力程度、咖啡因攝取、治療次數等變數若係數為正，表示其增加時焦慮分數也傾向提高。
- 睡眠時間、運動時數、飲食品質等變數若係數為負，表示較好的生活習慣可能與較低焦慮程度相關。
- 加入交互作用項後，模型表現提升，表示壓力與睡眠、咖啡因、運動之間可能存在共同影響。

實際應用上，此模型可作為心理健康機構、校園輔導單位或健康管理系統的初步風險篩檢輔助工具。不過，此模型不可取代專業心理諮商或醫療診斷。

三、GPT 輔助內容

本作業使用 GPT / Code Agent 協助完成以下內容：

- 建立 `.agent/skills` 與 `.agent/records`，紀錄作業規格、CRISP-DM 進度與對話摘要。
- 協助選定 Social Anxiety Dataset 並判斷其適合作為多元線性回歸資料集。
- 協助撰寫 Jupyter Notebook 中的 CRISP-DM 六階段內容。
- 協助完成資料前處理、特徵工程、類別編碼、標準化與 train-test split。
- 協助建立三個 LinearRegression 模型版本。
- 協助產生模型評估表、預測圖、95% confidence interval 與模型比較圖。
- 協助整理報告草稿與繳交檢查清單。

GPT 對話紀錄來源：

- `.agent/records/CHAT_LOG.md`
- 另需使用 pdfCrowd 或瀏覽器列印功能，將 GPT 對話過程匯出為 PDF，並附於報告或壓縮檔中。

四、NotebookLM 研究摘要

【NotebookLM 研究摘要：多元線性回歸應用於社交焦慮預測】

本摘要探討網路上針對「社交焦慮與生活型態」主題的主流預測解法。在 Kaggle 平台上，許多解法傾向使用隨機森林或梯度提升樹等複雜演算法以追求高準確度（例如梯度提升模型 R^2 可達 0.778）。然而，為了提升模型的「可解釋性」，本研究聚焦於多元線性回歸的應用。資料分析顯示，壓力等級、睡眠時數與治療頻率是影響焦慮程度的最核心特徵。網路上更優的線性回歸解法並非盲目放入所有變數，而是強調進行嚴謹的「特徵選擇」，並進一步引入「交互作用項」（例如：壓力 $\times$ 睡眠時數），藉此深入探討睡眠是否能緩衝壓力對焦慮造成的影響。綜合而言，結合特徵選擇與合理交互作用項的進階多元線性回歸，不僅能將模型解釋力（ R^2 ）從單純加法模型的 0.679 有效提升至 0.710，更能明確揭示各變數的影響方向（如壓力呈正相關、充足睡眠呈負相關）。此作法在保持模型透明度的同時，非常適合實際應用於心理健康機構的初步風險篩檢。

五、網路上主流或更優解法之比較

本作業主題要求使用 Multiple Linear Regression，因此主模型限制為 LinearRegression。不過，網路上常見的更強方法會使用 Ridge Regression、Lasso Regression、ElasticNet、Random Forest 或 Gradient Boosting 等模型。

先前檢查 social-anxiety-and-lifestyle-analysis.ipynb 時，該 notebook 採用多模型比較流程，結果大致如下：

方法	R2	RMSE	說明
Ridge Regression	約 0.736	約 1.105	線性模型加入 L2 正則化，表現接近本作業模型
Random Forest	約 0.773	約 1.026	非線性集成模型，可捕捉更複雜關係
Gradient Boosting	約 0.778	約 1.014	該比較中表現最佳，但不符合本作業主模型限制


與本作業最佳模型 Model 3 Interaction Terms 相比：

- 本作業 Model 3：R2 = 0.744755，RMSE = 1.087530。
- Gradient Boosting 表現較好，可能因為它能捕捉非線性關係與複雜特徵交互作用。
- 但本作業要求多元線性回歸，因此仍以 LinearRegression 作為主模型。
- Model 3 加入交互作用項後，已在保持線性模型可解釋性的前提下提升表現。

六、預測結果與圖表整理


1. outputs/anxiety_level_distribution.png

- 說明目標變數分布。




2. outputs/important_feature_scatterplots.png

- 說明壓力、睡眠、運動、咖啡因與焦慮程度的關係。




3. outputs/numeric_correlation_heatmap.png

- 說明數值特徵與目標變數的相關性。



4. outputs/model_evaluation_comparison.png

- 比較三個 LinearRegression 模型的 R2、MAE、RMSE。



5. outputs/prediction_plot_with_ci.png

- 呈現最佳模型的預測結果與 95% confidence interval。

