

The provided text outlines a **synthetic dataset** designed to facilitate mental health modeling and behavioral analysis related to **social anxiety**. It contains over **10,000 samples** that track a diverse range of features, including **demographics, lifestyle habits, and physiological stress indicators** such as heart and breathing rates. The documentation details the data structure, noting a lack of missing values and the inclusion of **anxiety levels** as a primary target for machine learning tasks. Additionally, the source provides **Python code** for initial data exploration, preprocessing, and feature engineering to assist researchers in identifying patterns. Ultimately, this resource serves as a comprehensive tool for studying the complex factors that influence **mental health outcomes** and intervention planning.

2026-05-17T03:44:24.246Z You Asked 

這是一份作業 整理一下 老師要我做什麼

這份作業（HW3：多元線性回歸問題）的主要目標是要求你使用真實資料集，遵循 **CRISP-DM 流程** 來完成一次完整的**多元線性回歸 (Multiple Linear Regression)** 分析 [1]。繳交期限為 **2026年5月26日** [1]。

以下為老師要求你完成的具體任務與規定整理：

1. 資料集選擇

- **來源與條件**：必須從 Kaggle 選擇一個具備 **10 至 20 個特徵 (features)** 的公開資料集，主題不限 [1]。
- **必須標示**：報告中需明確標明資料集來源與連結 [1]。
- (註：老師在作業說明後方有提供推薦清單，包含波士頓房價、車輛油耗、紅酒品質等資料集供你參考 [2-4])。

2. 模型分析要求

- **演算法**：使用線性回歸模型（單純線性回歸、多元線性回歸或 Auto Regression 皆可）進行預測任務 [1]。
- **必做步驟**：必須執行**特徵選擇 (Feature Selection)** 與 **模型評估 (Model Evaluation)** [1]。

- **圖表規定：**報告中必須提供**預測圖**，且圖上需加上**信賴區間 (Confidence Interval) 或預測區間 (Prediction Interval)** [1]。
- **分析框架：**必須完整遵循 **CRISP-DM 的六大步驟**進行說明（業務理解、資料理解、資料準備、建模、評估、部署）[1]。

3. AI 工具使用規定

- **ChatGPT：**所有與 ChatGPT 的對話紀錄，必須匯出成 PDF（老師建議可用 pdfCrowd 或其他方式）[1]。
- **NotebookLM：**需要利用 NotebookLM 研究網路上同主題的解法，並撰寫一份 **100 字以上的摘要**放入報告中 [1]。
- **清楚標示：**報告內必須明確標示出「GPT 輔助內容」與「NotebookLM 摘要」[1]。
- **延伸比較：**報告中需包含網路上主流或更優解法的比較與說明 [1]。

4. 繳交格式

你需要將所有檔案壓縮成一個**以學號命名的 ZIP 檔**（例如：`7114056XXX_hw2.zip`）進行上傳，壓縮檔內須包含以下兩個檔案 [1]：

1. **主程式：**命名為 `學號_hw2.py` 或 `學號_hw2.ipynb` [1]。
 2. **報告檔 (PDF)：**內容須包含 CRISP-DM 分析流程、GPT 對話過程、NotebookLM 研究摘要，以及與主流解法的比較 [1]。
- (加分/選用規定：若將專案上傳至 GitHub 或以 Colab 撰寫，可提供連結並在 `README.md` 中整理流程與成果) [2]。

5. 評分標準重點

- **文件說明佔 50%：**包含 CRISP-DM 流程完整且邏輯清楚 (25%)、附上 GPT 對話與 NotebookLM 摘要 (15%)、明確說明資料來源與研究脈絡 (10%) [2]。
- **結果呈現佔 50%：**模型可正確執行並具備特徵選擇與評估 (25%)、結果合理美觀具說服力 (15%)、呈現 Kaggle 名次或預測圖與評估指標 (10%) [2]。

請問你目前已經決定好要挑選哪一個 Kaggle 資料集了嗎？如果需要，我也可以針對 CRISP-DM 的六個步驟提供更詳細的撰寫建議。

2026-05-19T11:59:15.087Z You Asked 

這是一份jupyter notebook檔案 請幫我看一下

我已經幫你看過這份 Jupyter Notebook 檔案了。這是一份針對「社交焦慮與生活型態 (Social Anxiety Dataset)」資料集所做的完整數據分析 [1]。目前的程式碼寫得相當不錯，包含了資料載入、前處理、特徵工程、探索性資料分析 (EDA)，以及多種模型的訓練與評估 [2-5]。

不過，若要符合你老師的「HW3：多元線性回歸問題」作業要求，這份 Notebook 還缺少幾個關鍵步驟。以下我幫你整理出「已符合」與「需要修改/補齊」的地方：

✅ 目前已符合作業要求的部分：

1. **資料集選擇**：你挑選的資料集包含 年齡、睡眠時間、壓力等級、心率等共 19 個特徵 [6, 7]，符合老師規定「10 至 20 個特徵 (features) 的公開資料集」的要求 [8]。
2. **模型評估 (Model Evaluation)**：程式碼中已經有使用 MAE、RMSE 與 R^2 來評估模型表現 [5]，這點符合規定 [8]。

⚠️ 需要修改與補齊的重點（非常重要，攸關評分）：

1. 補上「預測圖與信賴區間」（結果呈現佔比重 10%）

- **現況**：程式碼最後只印出了各個模型的評估分數（如 $R^2 = 0.773$ 等）[5]，就結束了。
- **修改建議**：作業明確要求「請提供預測圖(加上信賴區間或預測區間)」[8]。你必須在程式碼最後加上一段視覺化，畫出預測值 (Predicted) 與實際值 (Actual) 的散佈圖，並利用如 `seaborn.regplot` 等套件畫出帶有信賴區間 (Confidence Interval) 的回歸線。

2. 補上明確的「特徵選擇 (Feature Selection)」步驟 (結果呈現佔比重 25%)

- **現況**：你有做特徵工程 [3]，且在第 10 步驟計算了「特徵重要性 (Feature Importance Analysis)」(例如壓力等級最重要佔 0.4700) [9]。
- **修改建議**：作業規定「必須執行特徵選擇」[8]。建議你在算出特徵重要性後，加上一個具體動作：只挑選前 N 個最重要的特徵（例如前 10 個），然後重新訓練一次線性回歸模型，並比較選擇特徵前後的模型表現差異。

3. 模型重點應拉回「多元線性回歸」

- **現況**：你訓練了 Random Forest、Ridge、Lasso、ElasticNet 與 Gradient Boosting，並得出 Gradient Boosting 表現最好 ($R^2=0.778$) 的結論 [5, 10]。
- **修改建議**：雖然這顯示了你的建模能力，但這次作業的主題是「多元線性回歸問題」[8]。建議你在結論或模型比較中，特別把 Ridge、Lasso 或原生的 LinearRegression 的結果拿出來當作主角，並說明為何它們的表現（例如 Ridge 的 $R^2=0.736$ [5]）與樹狀模型有差異。

4. 加上 CRISP-DM 六大步驟標題 (文件說明佔比重 25%)

- **現況：**你的 Markdown 標題目前是「1. DATA LOADING」、「2. DATA PREPROCESSING」等 [2, 3]。
- **修改建議：**老師要求「按照 CRISP-DM 說明的分析流程」[8]。請在 Jupyter Notebook 中插入 Markdown 區塊，明確標示出 CRISP-DM 的六個階段：
 - **Business Understanding (業務理解)：**介紹預測焦慮等級的目的。
 - **Data Understanding (資料理解)：**對應到你的 EDA [4]。
 - **Data Preparation (資料準備)：**對應到你的資料清理與特徵工程 [3]。
 - **Modeling (建模)：**對應到你的模型訓練 [5]。
 - **Evaluation (評估)：**對應到你的交叉驗證與 R^2 評估 [5]。
 - **Deployment (部署)：**寫一段文字說明這個模型未來可以怎麼應用（例如幫助心理健康機構做初步篩檢）。

報告與繳交提醒：


寫完 Notebook 後，別忘了你的 **PDF 報告檔** 還需要包含：

1. **NotebookLM 研究摘要：**請針對「預測焦慮症或多元線性回歸」的主題，用 NotebookLM 研究並寫 100 字以上摘要，需明確標示 [8]。
2. **與主流解法的比較：**在 Kaggle 或網路上找一下別人怎麼做，寫一段比較說明 [8]。
3. **匯出對話：**將我們討論的 ChatGPT 紀錄匯出成 PDF [8]。
4. **命名壓縮：**把 學號_hw2.ipynb 和 報告.pdf 包成 學號_hw2.zip 繳交 [8]（注意：雖然作業標題寫 hw3，但老師內文檔案命名範例是寫 hw2，建議與同學或老師確認一下檔名規定）。

需要我幫你寫出「特徵選擇」或「畫出帶有信賴區間的預測圖」的 Python 程式碼讓你補進去嗎？

2026-05-19T12:08:18.180Z You Asked 

請參考pdf 與jupyter 撰寫一份 完整的spec 可以使我的code agent 清晰的從0寫完此分析專案



這是一份為你的 Code Agent 量身打造的「系統提示詞 (System Prompt) / 規格書 (Spec)」。你可以直接將以下內容複製並貼給你的 Code Agent（例如 Cursor、ChatGPT 或是 GitHub Copilot），它就能清楚理解作業規定、CRISP-DM 框架，並幫你從頭到尾寫出符合老師要求的 Jupyter Notebook 程式碼。

Code Agent 專案開發規格書 (Spec)

專案概述

本專案為大學資料科學作業「HW3：多元線性回歸問題」[1]。請使用 Python 撰寫一份完整的 Jupyter Notebook（.ipynb）。本專案需嚴格遵循 **CRISP-DM 的六大階段** 進行 Markdown 標題排版與流程說明[1, 2]。預測目標為利用個人的生活習慣、背景與生理數據，建立「多元線性回歸 (Multiple Linear Regression)」模型來預測「焦慮程度 (Anxiety Level)」[3, 4]。

資料集資訊

- **來源**：Kaggle - Social Anxiety Dataset [1, 5]。
- **資料筆數**：11,000 筆，無缺失值 [4]。
- **特徵數量**：19 個（包含數值與類別型變數），符合 10~20 個特徵的作業規定 [1, 4]。
- **目標變數 (Y)**：Anxiety Level (1-10) [4, 6]。
- **自變數 (X)**：年齡、性別、睡眠時間、運動時數、咖啡因攝取、壓力等級等 [3, 6, 7]。

開發步驟與 CRISP-DM 階段要求

請在 Jupyter Notebook 中使用 Markdown 建立以下六個標題，並在各標題下撰寫對應的程式碼與文字說明：

1. Business Understanding (商業理解)

- **說明任務**：探討生活習慣、壓力與個人背景因素是否會影響焦慮程度 [3]。
- **成功指標**：利用多元線性回歸模型解釋焦慮分數，並以 R^2 、MAE、RMSE 評估模型準確度 [4]。

2. Data Understanding (資料理解)

- **資料載入與檢查**：使用 `pandas` 讀取資料，印出 `df.shape`、`df.info()`、`df.describe()` 與缺失值檢查 [8-10]。
- **探索性資料分析 (EDA)**：
 - 畫出目標變數 Anxiety Level (1-10) 的分佈直方圖 [11]。
 - 畫出重要特徵（如 Stress Level，Sleep Hours 等）與焦慮等級的散佈圖 (Scatter plot) [12]。
 - 畫出數值特徵的相關係數熱力圖 (Correlation Heatmap) [13]。

3. Data Preparation (資料準備)

- **特徵工程 (Feature Engineering)**：請建立以下衍生變數以提升模型解釋力：

- `Sleep_Activity_Score` = 睡眠時數 * 運動時數 [14]。
- `Stimulant_Index` = 咖啡因攝取 + 酒精攝取 * 10 [14]。
- `Diet_Stimulant_Balance` = 飲食品質 - (`Stimulant_Index` / 100) [14]。
- **類別編碼**：將二元變數 (Yes/No) 轉換為 1/0；使用 `pd.get_dummies` (One-Hot Encoding) 處理 `Gender`、`Occupation` 等類別變數 [4, 10]。
- **資料分割與標準化**：將資料切分為 80% 訓練集與 20% 測試集 (`random_state=42`) [15, 16]。接著使用 `StandardScaler` 對數值特徵進行標準化 [17, 18]。

4. Modeling (建模) 【⚠️ 作業核心規定】

- **演算法限制**：請使用 `sklearn.linear_model.LinearRegression`，**不要**使用 Random Forest 或 Gradient Boosting [1]。
- **模型訓練需包含以下三個版本**：
 1. **Model 1 (Baseline 基礎模型)**：放入所有數值化與轉換後的變數進行單純加法型多元線性回歸 [15, 19]。
 2. **Model 2 (特徵選擇 Feature Selection)**：【必做要求】依據 Model 1 的特徵重要性或係數大小，挑選出前 10 個最重要的變數（例如 `Stress Level`，`Sleep Hours`，`Therapy Sessions` 等）重新訓練一個模型 [1, 20]。
 3. **Model 3 (含交互作用項 Interaction Terms)**：加入合理的特徵相乘項（如 `Stress × Sleep`：探討睡眠是否會減弱壓力對焦慮的影響；`Stress × Caffeine` 等）建立進階線性模型，以提升 R^2 分數 [19, 21]。

5. Evaluation (評估) 【⚠️ 作業核心規定】

- **指標計算**：分別計算並印出 Model 1, 2, 3 的 R^2 、`MAE`、`RMSE` 分數 [16]。
- **預測圖與信賴區間 (Prediction Plot with CI)**：【必做要求】針對表現最好的模型，繪製出「實際值 vs. 預測值 (Actual vs. Predicted)」的散佈圖，並且**必須疊加畫出回歸線與信賴區間 (Confidence Interval)**，建議可使用 `seaborn.regplot(x=y_test, y=y_pred, ci=95)` 來達成 [1]。

6. Deployment (部署與結論)

- **總結變數影響方向**：根據回歸係數說明結論。例如：壓力程度與咖啡因攝取呈正向影響（增加焦慮）；睡眠時數與飲食品質呈負向影響（降低焦慮） [22, 23]。
- **應用場景說明**：簡述此模型可如何實際應用（例如：提供心理健康機構做初步風險篩檢）。


輸出限制

1. 請產出完整且可直接執行的 Python 程式碼，並在適當的地方加入繁體中文的 `print()` 與註解。
2. 請確保使用 `matplotlib.pyplot` 與 `seaborn` 進行圖表繪製。

💡 **給你的建議：** 你把上述這份 Spec 交給 AI 寫程式後，它會產出一個完整的 學號_hw2.ipynb 內容。執行完畢後，你只需要**自行準備一份 PDF 報告**，把這份 Notebook 裡的圖表、NotebookLM 的摘要（需 100 字以上）、主流解法比較，以及與 ChatGPT 討論的紀錄（使用 pdfCrowd 匯出）放進去，壓縮成 學號_hw2.zip 就可以繳交了[1]！

2026-05-19T12:24:28.846Z You Asked 

請輸出一份 研究摘要 200字左右



這是一份為你準備的 **NotebookLM 研究摘要**，字數約 250 字左右，你可以直接將這段內容放入你的 PDF 報告中以符合作業規定：

【NotebookLM 研究摘要：多元線性回歸應用於社交焦慮預測】

本摘要探討網路上針對「社交焦慮與生活型態」主題的主流預測解法。在 Kaggle 平台上，許多解法傾向使用隨機森林或梯度提升樹等複雜演算法以追求高準確度（例如梯度提升模型 R^2 可達 0.778）[1]。然而，為了提升模型的「可解釋性」，本研究聚焦於多元線性回歸的應用 [2]。

資料分析顯示，壓力等級、睡眠時數與治療頻率是影響焦慮程度的最核心特徵 [3]。網路上更優的線性回歸解法並非盲目放入所有變數，而是強調進行嚴謹的「特徵選擇」，並進一步引入「交互作用項」（例如：壓力 $\times$ 睡眠時數），藉此深入探討睡眠是否能緩衝壓力對焦慮造成的影響 [2, 4]。

綜合而言，結合特徵選擇與合理交互作用項的進階多元線性回歸，不僅能將模型解釋力（ R^2 ）從單純加法模型的 0.679 有效提升至 0.710 [2, 5]，更能明確揭示各變數的影響方向（如壓力呈正相關、充足睡眠呈負相關）[5]。此作法在保持模型透明度的同時，非常適合實際應用於心理健康機構的初步風險篩檢 [6]。